

InDigital XP

PROYECTO PEOPLE ANALYTICS · DOCUMENTO 3

Data Foundation Blueprint

Data Landscape & Data Readiness Strategy ·
plazaVea & Vivanda

ESTRATEGIA DE DATOS

Versión 1.0

Estado: Draft

CONTROL DEL DOCUMENTO

Documento	Data Foundation Blueprint	Cliente	Supermercados Peruanos
Proyecto	People Analytics	Audiencia	Data Platform · GH · Operaciones
Responsable	Business Analytics	Estado	DRAFT

OBJETIVO DEL DOCUMENTO

Definir la estrategia de datos que soportará el desarrollo de la solución de People Analytics, asegurando la **disponibilidad, calidad, integración, gobierno y trazabilidad** de toda la información requerida para los modelos de ausentismo y rotación.

Constituye la guía para Business Analytics, Data Platform, Gestión Humana y Operaciones respecto a las actividades necesarias para preparar los datos antes del desarrollo analítico.

TABLA DE CONTENIDO

01	Introducción	09	Estrategia de Integración
02	Arquitectura General	10	Estrategia de Calidad
03	Estado Actual (AS-IS)	11	Gobierno de Datos
04	Arquitectura Objetivo (TO-BE)	12	Seguridad
05	Inventario de Fuentes	13	Riesgos
06	Modelo Canónico del Colaborador	14	Roadmap Data Readiness
07	Data Owners	15	Recomendaciones
08	Data Readiness Assessment	A	Anexo · Variables Candidatas

01 Introducción


El éxito de una iniciativa de People Analytics depende principalmente de la capacidad para integrar información proveniente de **múltiples dominios funcionales**.

Actualmente la información relacionada con colaboradores, operación, productividad y gestión humana se encuentra distribuida entre diferentes plataformas tecnológicas, dificultando la construcción de una **visión única del colaborador**.

Este documento propone una estrategia integral para consolidar dichas fuentes dentro del **ecosistema analítico corporativo**, preparando los datos antes de iniciar el desarrollo de modelos.

02 Arquitectura General

La arquitectura propuesta organiza el flujo de datos desde los sistemas fuente hasta los modelos y el dashboard ejecutivo, centralizando todo dentro de Google Cloud Platform.



03 Estado Actual (AS-IS)

Actualmente las fuentes se encuentran distribuidas entre múltiples sistemas, sin una llave única ni una capa de integración común.

3.1 Sistemas identificados

SISTEMA	OBSERVACIÓN
SharePoint	Archivos manuales
Azure SQL	Datos operativos
Kronos	Asistencia y horarios
BI Reports	Información consolidada
Excel	Archivos descentralizados

3.2 Principales problemas

▲ Información duplicada

▲ No existe una llave única integrada

▲ Frecuencias de actualización distintas


▲ Distintas granularidades

▲ Procesos manuales

▲ Dependencia de archivos

04 Arquitectura Objetivo (TO-BE)

La solución propuesta contempla la centralización de todas las fuentes dentro de GCP, organizadas por capas con responsabilidades claras.



05 Inventario de Fuentes

El inventario de fuentes es una de las matrices más importantes del proyecto: identifica cada fuente, su sistema, su owner, frecuencia, historia disponible y estado de disponibilidad.

5.1 Inventario General

FUENTE	SISTEMA	OWNER	FRECUENCIA	HISTORIA	ESTADO
Maestro Colaboradores	RRHH	GH	Diario	2022	Pendiente
Rotación	RRHH	GH	Mensual	2022	Disponible
Ausentismo	Kronos	Operaciones	Diario	2022	Pendiente
Horarios	Kronos	Operaciones	Diario	2022	Pendiente
Horas Extras	SharePoint	GH	Mensual	2022	Pendiente
Clima Laboral	Encuestas	GH	Semestral	2022	Pendiente
Liderazgo	Encuestas	GH	Semestral	2022	Pendiente
Productividad	Azure	Operaciones	Diario	2022	Disponible
Ventas	Azure	Comercial	Diario	2022	Disponible


5.2 Clasificación por dominio

RRHH - Maestro colaboradores - Reclutamiento - Ceses - Contratos	Operaciones - Productividad - Dotación - Cobertura	Kronos - Asistencia - Tardanzas - Horarios - Horas trabajadas
Comercial - Ventas - Flujo de clientes	Encuestas - Clima - Liderazgo	

06 Modelo Canónico del Colaborador

Antes de pensar en modelos debemos definir qué representa un **colaborador** para el proyecto y cómo se relacionan sus entidades.

6.1 Entidades



6.2 Llave Maestra

LLAVE ÚNICA DE INTEGRACIÓN

ID_COLABORADOR_HASH

Permite unir de forma segura y consistente todas las fuentes alrededor de un único identificador del colaborador, sin exponer datos personales sensibles.

07

Data Owners

Se involucra oficialmente a Operaciones y Data Platform, definiendo responsables por cada fuente.

FUENTE	DATA OWNER	DATA ENGINEER
RRHH	Gestión Humana	RRHH
Kronos	Operaciones	Operaciones
Productividad	Operaciones	BI
Ventas	Comercial	Data Platform

08


Data Readiness Assessment

Evalúa, fuente por fuente, si existe, su calidad, disponibilidad, integrabilidad y prioridad para el MVP.

FUENTE	EXISTE	CALIDAD	DISPONIBLE	INTEGRABLE	PRIORIDAD
Colaboradores	✓	Alta	✓	✓	Alta
Kronos	✓	Alta	Parcial	✓	Alta
Clima	✓	Media	No	Parcial	Media
Liderazgo	✓	Media	No	Parcial	Media
Horas Extras	✓	Baja	No	No	Alta

09 Estrategia de Integración

Data Platform liderará el proceso de integración, llevando cada fuente desde el sistema origen hasta el Feature Store mediante etapas validadas.



10 Estrategia de Calidad

Se definirán reglas de calidad aplicadas en la etapa de validación. Ejemplos:

DIMENSIÓN	REGLA
Edad	No puede ser negativa.
Fecha de ingreso	Debe ser menor a la fecha de salida.
Horas extras	No pueden superar un umbral definido.
Duplicados	Una única llave por colaborador.
Integridad	Cobertura referencial del 100% entre tablas.

11 Gobierno de Datos

Se definirán roles claros de gobierno para cada fuente del proyecto:

Data Owner

Responsable de la fuente y de las decisiones sobre su uso.

Data Engineer

Construye y mantiene los pipelines, asegurando la calidad y consistencia operativa del dato.

Business Owner

Define las necesidades y el valor de negocio del dato.

Custodio Técnico

Administra el almacenamiento, acceso y seguridad técnica.

12 Seguridad

El proyecto maneja información sensible de colaboradores; por ello se aplicarán los siguientes controles base:

Permisos

Acceso por rol

Auditoría

Trazabilidad de uso

Cifrado

En reposo y tránsito

PROPUESTA Anonimización del colaborador

Sujeta a validación con el cliente. Recomendamos evaluar su adopción si se considera necesario según las políticas de privacidad y protección de datos de SPSA:

Enmascaramiento

Ocultar datos sensibles en consultas y reportes.

Hash de DNI

Identificador anónimo como llave de integración.

13 Riesgos

RIESGO	IMPACTO	MITIGACIÓN
No existe historia suficiente	Alto	Buscar históricos disponibles desde 2022.
Fuentes manuales	Alto	Automatización de la captura.
Información duplicada	Alto	Reglas de calidad y llave única.
Dependencia de SharePoint	Medio	Migración a pipeline automatizado.
Retrasos en integración	Alto	Involucrar a Data Platform desde el inicio.

14 Roadmap Data Readiness

Secuencia de hitos para llevar los datos desde el inventario inicial hasta el estado **Ready for Analytics**.

01 Inventario

02 Validación

03 Accesos

04 Integración

05 Calidad

06 Modelo Canónico

07 Data Mart

08 Feature Store

09 Ready for Analytics

15 Recomendaciones

Corto plazo

- Consolidar el inventario de fuentes.
- Validar disponibilidad histórica desde 2022.
- Identificar data owners y responsables funcionales.
- Priorizar las fuentes críticas para el MVP.

Mediano plazo

- Centralizar la información en GCP.
- Construir pipelines automatizados.
- Implementar controles de calidad.
- Definir el modelo canónico del colaborador.

Largo plazo

- Implementar un Feature Store corporativo de People Analytics.
- Incorporar monitoreo de calidad de datos.
- Estandarizar procesos de integración para futuros proyectos.

A Anexo • Variables Candidatas

Catálogo inicial de variables candidatas, organizado por dominio. Se refinará durante el proyecto.

DOMINIO	EJEMPLOS
Demográficas	Edad, sexo, estado civil, distrito, nivel educativo
Laborales	Antigüedad, cargo, área, tipo de contrato, jornada
Operativas	Horas extras, tardanzas, ausencias, cambios de turno
Organizacionales	Tienda, supervisor, dotación, productividad
Encuestas	Clima, liderazgo, engagement
Geográficas	Distancia hogar-tienda, tiempo estimado de viaje
Temporales	Mes, campaña, feriados, estacionalidad